

2016-2017 学年秋季学期 试题专用纸

中国科学院大学

试题专用纸

课程编号: 091M4042H


课程名称: 模式识别与机器学习

任课教师: 黄庆明、山世光、兰艳艳、郭嘉丰

注意事项:

1. 考试时间为 120 分钟, 考试方式 闭卷;
2. 全部答案写在答题纸上;
3. 考试结束后, 请将本试卷和答题纸、草稿纸一并交回。

1. (6分) 简述模式的概念和它的直观特性, 并简要说明模式分类有哪几种主要方法。
2. (8分) 假设某研究者在 ImageNet 数据上使用线性支持向量机 (Linear SVM) 来做文本分类的任务, 请说明在如下情况下分别如何操作才能得到更好的结果, 并说明原因。
 - (1) 训练误差5%, 验证误差10%, 测试误差10%。
 - (2) 训练误差1%, 验证误差10%, 测试误差10%。
 - (3) 训练误差1%, 验证误差3%, 测试误差10%。
3. (8分) 给定如下概率图模型, 其中变量 X_5 为已观测变量, 请问变量 X_4 和 X_6 是否独立? 并用概率推导证明之。



4. (10分) (1) 随机猜测作为一个分类算法是否一定比 SVM 差? 借此阐述你对 “No Free Lunch Theorem” 的理解。(2) 举例阐述你对 “Occam’s razor” 的理解。
5. (10分) 详细描述 AdaBoost 的原理并给出算法, 并解释为什么 AdaBoost 经常可以在训练误差为 0 后继续训练还可能带来测试误差的继续下降。
6. (10分) 用感知器算法求下列模式分类的解向量 (取 $w(1)$ 为零向量)
 $\omega_1: \{(0\ 0\ 0)^T, (1\ 0\ 0)^T, (1\ 0\ 1)^T, (1\ 1\ 0)^T\}$
 $\omega_2: \{(0\ 0\ 1)^T, (0\ 1\ 1)^T, (0\ 1\ 0)^T, (1\ 1\ 1)^T\}$

7. (12 分) 设以下模式类别具有正态概率密度函数:

$$\omega_1: \{(0 \ 0 \ 0)^T, (1 \ 0 \ 0)^T, (1 \ 0 \ 1)^T, (1 \ 1 \ 0)^T\}$$

$$\omega_2: \{(0 \ 1 \ 0)^T, (0 \ 1 \ 1)^T, (0 \ 0 \ 1)^T, (1 \ 1 \ 1)^T\}$$

若 $P(\omega_1)=P(\omega_2)=0.5$, 求这两类模式之间的贝叶斯判别界面的方程式。

8. (12 分) 假设有如下线性回归问题,

$$\min_{\beta} (y - X\beta)^2 + \lambda \|\beta\|_2^2$$

其中 y 和 β 是 n 维向量, X 是一个 $m \times n$ 的矩阵。

该线性回归问题的参数估计可看作一个后验分布的均值, 其先验为高斯分布 $\beta \sim N(0, \tau I)$, 样本产生自高斯分布 $y \sim N(X\beta, \sigma^2 I)$, 其中 I 为单位矩阵, 试推导调控系数 λ 与方差 τ 和 σ^2 的关系。

9. (12 分) 给定有标记样本集 $D_l = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$ 和未标记样本 $D_u = \{(x_{l+1}, y_{l+1}), (x_{l+2}, y_{l+2}), \dots, (x_{l+u}, y_{l+u})\}$, $l \ll u$, $l + u = m$, 假设所有样本独立同分布, 且都是由同一个包含 N 个混合成分的高斯混合模型 $\{(\alpha_i, \mu_i, \Sigma_i) | 1 \leq i \leq N\}$ 产生, 每个高斯混合成分对应一个类别, 请写出极大似然估计的目标函数 (对数似然函数), 以及用 EM 算法求解参数的迭代更新式。

10. (12 分) 假定对一类特定人群进行某种疾病检查, 正常人以 ω_1 类代表, 患病者以 ω_2 类代表。设被检查的人中正常者和患病者的先验概率分别为

$$\text{正常人: } P(\omega_1) = 0.9$$

$$\text{患病者: } P(\omega_2) = 0.1$$

现有一被检查者, 其观察值为 x , 从类条件概率密度分布曲线上查得

$$P(x | \omega_1) = 0.2, P(x | \omega_2) = 0.4$$

同时已知风险损失函数为

$$\begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix} = \begin{pmatrix} 0 & 6 \\ 1 & 0 \end{pmatrix}$$

其中 λ_{ij} 表示将本应属于第 j 类的模式判为属于第 i 类所带来的风险损失。试对该被检查者用以下两种方法进行分类:

- (1) 基于最小错误率的贝叶斯决策, 并写出其判别函数和决策面方程;
- (2) 基于最小风险的贝叶斯决策, 并写出其判别函数和决策面方程。

2018-2017

1. 模式是抽取自物体的信息集合, 既包含空间部分, 又包含时间部分.

直观特性: 可观察性, 可区分性, 相似性

主要方法: 监督学习: 概念驱动, 归纳假设

非监督学习: 数据驱动, 演绎假设

2. (1) 欠拟合, 换用复杂度更高的模型

(2) 过拟合, 换用复杂度更低的模型

(3) 测试数据与训练数据不是独立同分布的, 更换测试数据集

4. (1) 不一定, 在无先验知识的情况下, 无法断言一个模型比另一个更好.

对特定的问题为了获得更好的效果需要选用更复杂的模型.

(2) 训练数据来自添加高斯噪声的 $y = \sin x$ ($x \in [0, 2\pi]$). 训练
使用不同的多项式函数拟合, 三次的效果最佳. 在同等错误
率的条件下, 简单模型具有更小的方差, 更好的泛化能力.

5. $\{x_i, y_i\}_{i=1}^n$

$$D(i) = \frac{1}{n}$$

for 1 to T:

训练弱分类器 h_i

$$D_{(i)}^{t+1} = D_{(i)}^t \cdot e^{-\alpha_i y_i h_i(x_i)}$$

通过弱分类器的组合, 得到强分类器.

每次训练弱分类器后, 对分类错误的

样本, 增加权重使得后续弱分类器

更加“关注”该样本, 以达到提升

分类效果的目的.

其中 $\alpha_i = \frac{1}{2} \ln \frac{1-\epsilon}{\epsilon}$, $\epsilon = P(h_i(x) \neq y) < 0.5$

$$H_{\text{final}} = \sum \alpha_i h_i(x)$$

当训练误差为零后, Adaboost 会继续增大

分类问题, 提升模型的泛化能力, 减少测试误差.

6. $w(1) = (0, 0, 0, 0)^T$, 对 w_2 的样本取相反数

增加数据: $w_1 = \{(0, 0, 0, 1)^T, (1, 0, 0, 0)^T, (0, 1, 1)^T, (1, 1, 0, 1)^T\}$

$w_2 = \{(0, 0, 0, -1)^T, (-0, -1, -1, 1)^T, (-0, 1, 0, 1)^T, (1, 1, -1, 1)^T\}$

更新规则: $w(k+1) = \begin{cases} w(k) & w(k)^T x(k) > 0 \\ w(k) + x(k+1) & \text{其它} \end{cases}$ (以下省略不更新的步骤)

$x(1) = (0, 0, 0, 1)^T$, $w(1)^T x(1) = 0$ 更新: $w(2) = (0, 0, 0, 1)^T$

$x(2) = (0, 0, -1, -1)^T$, $w(2)^T x(2) = -1$ 更新: $w(3) = (0, 0, -1, 0)^T$

$x(3) = (0, 1, 0, -1)^T$, $w(3)^T x(3) = 0$ 更新: $w(4) = (0, -1, -1, -1)^T$

$x(4) = (0, 0, 0, 1)^T$, $w(4)^T x(4) = -1$, 更新: $w(5) = (0, -1, -1, 0)^T$

$x(5) = (1, 0, 0, 1)^T$, $w(5)^T x(5) = 0$, 更新: $w(6) = (1, -1, -1, 1)^T$

$x(6) = (0, 0, -1, -1)^T$, $w(6)^T x(6) = 0$, 更新: $w(7) = (1, -1, -2, 0)^T$

$x(7) = (0, 0, 0, 1)^T$, $w(7)^T x(7) = 0$, 更新: $w(8) = (1, -1, -2, 1)^T$

$x(8) = (1, 0, 1, 1)^T$, $w(8)^T x(8) = 0$, 更新: $w(9) = (2, -1, -1, 2)^T$

$x(9) = (0, 0, -1, -1)^T$, $w(9)^T x(9) = -1$, 更新: $w(10) = (2, -1, -2, 1)^T$

$x(10) = (0, -1, 0, -1)^T$, $w(10)^T x(10) = 0$, 更新: $w(11) = (2, -2, -2, 0)^T$

$x(11) = (0, 0, 0, 1)^T$, $w(11)^T x(11) = 0$, 更新: $w(12) = (2, -2, -2, 1)^T$

$w = w(12) = (2, -2, -2, 1)$

$$7. p(w_1|x) = \frac{p(x|w_1)p(w_1)}{p(x)}$$

$$p(w_2|x) = \frac{p(x|w_2)p(w_2)}{p(x)}$$

$$p(w_1|x) > p(w_2|x)$$

$$p(x|w_1)p(w_1) > p(x|w_2)p(w_2)$$

$$\frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} > 0$$

$$d(x) = \frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} = \frac{p(x|w_1)}{p(x|w_2)} - 1 = 0$$

假设给定 w 的样本 x_1, x_2, x_3 相互独立。

$$p(x|w) = p(x_1, x_2, x_3|w) = p(x_1|w)p(x_2|w)p(x_3|w)$$

$$d(x) = \frac{\prod_{i=1}^3 p(x_i|w_1)}{\prod_{i=1}^3 p(x_i|w_2)} - 1 = 0$$

8.

$$p(\tilde{\beta} | \tilde{y}) = \frac{p(\tilde{y} | \tilde{\beta}, \tilde{x}, \sigma) \cdot p(\tilde{\beta} | \tau)}{p(\tilde{y})}$$

对数似然: $\log p(\tilde{\beta} | \tilde{y}) = \log p(\tilde{y} | \tilde{\beta}, \tilde{x}, \sigma) + \log p(\tilde{\beta} | \tau) - \log p(\tilde{y})$

$$= \log \prod_{i=1}^n p(y_i | \tilde{\beta}, \tilde{x}_i, \sigma) + \log \frac{1}{\sqrt{2\pi|\tau|}} \cdot e^{-\frac{1}{2}(\tilde{\beta} - \tilde{\alpha})^T (\tau I)^{-1} (\tilde{\beta} - \tilde{\alpha})} - \log p(\tilde{y})$$

$$= \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi|\sigma|}} e^{-\frac{1}{2}(y_i - \tilde{x}_i^T \tilde{\beta})(\sigma I)^{-1}(y_i - \tilde{x}_i^T \tilde{\beta})} + \left(-\frac{1}{2} \tilde{\beta}^T (\tau I)^{-1} \tilde{\beta}\right) + \text{constant}$$

$$= \sum_{i=1}^n -\frac{1}{2}(y_i - \tilde{x}_i^T \tilde{\beta})(\sigma I)^{-1}(y_i - \tilde{x}_i^T \tilde{\beta}) - \frac{1}{2} \tilde{\beta}^T (\tau I)^{-1} \tilde{\beta} + \text{constant}$$

$$= \sum_{i=1}^n -\frac{1}{2} \cdot \frac{1}{\sigma} (y_i - \tilde{x}_i^T \tilde{\beta})^T (y_i - \tilde{x}_i^T \tilde{\beta}) - \frac{1}{2} \cdot \frac{1}{\tau} \tilde{\beta}^T \tilde{\beta} + C$$

$$= -\frac{1}{2\sigma} (y - X\tilde{\beta})^2 - \frac{1}{2\tau} \|\tilde{\beta}\|^2 + C$$

$$= -\frac{1}{2\sigma} \left[(y - X\tilde{\beta})^2 + \frac{\sigma}{\tau} \|\tilde{\beta}\|^2 \right] + C$$

$$\max \log p(\tilde{\beta} | \tilde{y}) \Leftrightarrow \min (y - X\tilde{\beta})^2 + \frac{\sigma}{\tau} \|\tilde{\beta}\|^2 \quad \therefore \lambda = \frac{\sigma}{\tau}$$

9. $D_1 = \{(x_i, y_i) | i=1, \dots, L\}$ 已知, $D_m = \{(x_i, y_i) | i=L+1, \dots, m\}$ 未知

令 $z_{ik} = I(x_i, y_i = k)$, $\forall i, L+1 \leq i \leq m$, $\forall k, 1 \leq k \leq K$, $z_{ik} \sim B(1, p(y_i = k | x_i))$

E-step: $E(z_{ik}) = p(y_i = k | x_i) = \frac{p(x_i | y_i = k) p(y_i = k)}{p(x_i)} = \frac{p(x_i | y_i = k) p(y_i = k)}{\sum_{j=1}^K p(x_i | y_i = j) p(y_i = j)}$

M-step: $\prod_{i=1}^m p(x_i, y_i) = \prod_{i=1}^L p(x_i, y_i) \cdot \prod_{i=L+1}^m p(x_i, y_i)$

$\forall i, L+1 \leq i \leq m, p(x_i, y_i) = \prod_{j=1}^K p(x_i, y_i = j)^{z_{ij}}$

$$\prod_{i=1}^m p(x_i, y_i) = \prod_{i=1}^L p(x_i, y_i) \cdot \prod_{i=L+1}^m \prod_{j=1}^K p(x_i, y_i = j)^{z_{ij}}$$

对数似然: $\sum_{i=1}^L \log p(x_i, y_i) + \sum_{i=L+1}^m \sum_{j=1}^K z_{ij} (\log p(x_i | y_i = j) + \log p(y_i = j))$

$$= \sum_{i=1}^L \left[\log p(x_i) + \log p(y_i) \right] + \sum_{i=L+1}^m \sum_{j=1}^K z_{ij} \left(-\frac{1}{2} (x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j) + \log p(y_i = j) \right)$$

$\mu_j = \frac{\sum_{i=1}^L x_i I(y_i = j)}{\sum_{i=1}^L I(y_i = j)} + \frac{\sum_{i=L+1}^m x_i z_{ij}}{\sum_{i=L+1}^m z_{ij}} \quad \Sigma_j = \frac{1}{\sum_{i=1}^L I(y_i = j)} \sum_{i=1}^L (x_i - \mu_j)^2 I(y_i = j) + \frac{1}{\sum_{i=L+1}^m z_{ij}} \sum_{i=L+1}^m (x_i - \mu_j)^2 z_{ij}$

$p(y_i = j) = \frac{\sum_{i=1}^L I(y_i = j)}{L} + \frac{\sum_{i=L+1}^m z_{ij}}{m-L}$

$$10. (1) p(w_1|x) = \frac{p(x|w_1) \cdot p(w_1)}{p(x)}$$

$$p(w_2|x) = \frac{p(x|w_2) \cdot p(w_2)}{p(x)}$$

$$p(w_1|x) > p(w_2|x)$$

$$p(x|w_1) p(w_1) > p(x|w_2) p(w_2)$$

$$\frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} > 0$$

$$d(x) = \frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} = 0$$

$$d(x) = \frac{0.2}{0.4} - \frac{0.9}{0.1} = -7 < 0$$

$$\therefore x \in w_2$$

$$(2) r_1 = L_{11} \cdot p(x, w_1) + L_{12} \cdot p(x, w_2)$$

$$= 0 \cdot p(x|w_1) p(w_1) + 6 \cdot p(x|w_2) p(w_2)$$

$$= 0 + 6 \times 0.4 \times 0.1$$

$$= 0.24$$

$$r_2 = 0.18 < 0.24 = r_1$$

$$\therefore x \in w_2$$

$$r_2 = L_{22} \cdot p(x, w_2) + L_{21} \cdot p(x, w_1)$$

$$= 0 \cdot p(x|w_2) p(w_2) + 1 \times p(x|w_1) p(w_1)$$

$$= 0 + 1 \times 0.2 \times 0.9$$

$$= 0.18$$