


第七章：支持向量机


Support Vector Machine, SVM

- 线性支持向量机
- 核支持向量机
- 序列最小优化算法


线性分类器



线性分类器




线性分类器



➤ 间隔 (Margin)

■ Logistic 回归中


$$P(y = 1 | \mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}}$$



- $\mathbf{w}^T \mathbf{x}$ 越大, $y=1$ 的置信度越高
- 给定训练数据, 如果当 $y=1$ 时, $\mathbf{w}^T \mathbf{x} \gg 0$; 当 $y=-1$ 时, $\mathbf{w}^T \mathbf{x} \ll 0$, 则 \mathbf{w} 是一个比较好的参数。

■ 问题: 除了概率, 如何定义分类器的置信度?

间隔Margin



■ 将样本A、B、C分为哪一类？对于哪个样本的预测的置信度高？

点到分离超平面的距离反映了预测的置信度。

➤ 二分类问题-线性分类器

■ 样本 $(\mathbf{x}, y), y \in \{-1, 1\}$

■ 线性分类器:

$$f_{\mathbf{w}, b}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x} + b)$$

$$g(z) = \begin{cases} 1, & \text{如果 } z \geq 0 \\ -1, & \text{如果 } z < 0 \end{cases}$$

■ 超平面: $\mathbf{w}^T \mathbf{x} + b = 0$.

➤ 函数间隔(Functional Margin)

■ 对于一样训练样本 (\mathbf{x}^i, y^i) , 它到 (\mathbf{w}, b) 确定的超平面的函数间隔为:


$$\hat{\gamma}^i = y^i(\mathbf{w}^T \mathbf{x}^i + b)$$

- $y^i = 1$, $\mathbf{w}^T \mathbf{x}^i + b$ 是一个大的正数.
- $y^i = -1$, $\mathbf{w}^T \mathbf{x}^i + b$ 是一个比较小的负数.
- $y^i(\mathbf{w}^T \mathbf{x}^i + b) > 0$, 模型对样本的预测是正确的.
- 大的函数间隔 \rightarrow 确信的、正确的预测.

■ 对于训练数据集 $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$, 它的函数间隔定义为

$$\hat{\gamma} = \min_i \hat{\gamma}^i, i = 1, 2, \dots, N$$

几何间隔



- 对于样本 (x^i, y^i) $y^i = 1$ ，它到决策界面的距离 γ^i 是线段AB的长度。

$$\gamma^i = ?$$

几何间隔

■ 点B: $\mathbf{x}^i - \gamma^i \mathbf{w} / \|\mathbf{w}\|_2$

■ 点B在决策边界上。


$$\mathbf{w}^T (\mathbf{x}^i - \gamma^i \mathbf{w} / \|\mathbf{w}\|_2) + b = 0$$

■ 求解方程可得 :

$$\gamma^i = \frac{\mathbf{w}^T \mathbf{x}^i + b}{\|\mathbf{w}\|_2} = \left(\frac{\mathbf{w}}{\|\mathbf{w}\|_2} \right)^T \mathbf{x}^i + \frac{b}{\|\mathbf{w}\|_2}$$

■ 样本 (\mathbf{x}^i, y^i) 的几何间隔为:

$$\gamma^i = y^i \left(\left(\frac{\mathbf{w}}{\|\mathbf{w}\|_2} \right)^T \mathbf{x}^i + \frac{b}{\|\mathbf{w}\|_2} \right)$$



几何间隔

- 训练数据集 $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$ 关于判别界面 (参数为 (\mathbf{w}, b)) 的几何间隔:


$$\gamma = \min_i \gamma^i, i = 1, 2, \dots, N$$

- 函数间隔与几何间隔:

$$\gamma^i = \frac{\hat{\gamma}^i}{\|\mathbf{w}\|_2}, \quad \gamma = \frac{\hat{\gamma}}{\|\mathbf{w}\|_2}.$$

- 如果 $\|\mathbf{w}\|_2 = 1$, 二者相等。

- 几何间隔具有不变性。



➤ 最优间隔分类器


- 给定一个训练集，一个自然的想法是试图找到一个使**几何间隔最大化**的决策边界，这表示对训练集的有可信的预测并且对训练数据的良好“拟合”。

- 假设训练数据是线性可分的。

- 间隔最大化：

$$\max_{\gamma, \mathbf{w}, b} \gamma$$

$$s.t. \quad y^i \left(\left(\frac{\mathbf{w}}{\|\mathbf{w}\|_2} \right)^T \mathbf{x}^i + \frac{b}{\|\mathbf{w}\|_2} \right) \geq \gamma, i = 1, \dots, N$$



最优间隔分类器

问题转换:

$$\begin{aligned} \max_{\gamma, \mathbf{w}, b} & \frac{\hat{\gamma}}{\|\mathbf{w}\|_2} \\ \text{s.t.} & y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq \hat{\gamma}, i = 1, \dots, N \end{aligned}$$

简化问题

$$\begin{aligned} \min_{\mathbf{w}, b} & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t.} & y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq 1, i = 1, \dots, N \end{aligned}$$

可以使用现成的二次规划程式求解 (QP)。

• 例如Python中Cvxopt.solvers.qp(P,q,G,h,A,b), matlab中的函数是quadprog

二次规划(QP, Quadratic Programming)定义: 目标函数为二次函数, 约束条件为线性约束, 属于最简单的一种非线性规划。

线性SVM

■输入：线性可分的训练数据集 $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$

■输出：判别函数及决策/判别界面。

•通过求解如下最优化问题来得到最优分类器的参数 (\mathbf{w}^*, b)

•

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2$$

$$s.t. \quad y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq 1, i = 1, \dots, N$$

•分离超平面: $(\mathbf{w}^*)^T \mathbf{x} + b^* = 0$

•判别函数: $f_{\mathbf{w}, b}(\mathbf{x}) = \text{sign}((\mathbf{w}^*)^T \mathbf{x} + b^*)$

理论保证：对于线性可分的训练数据集，最大间隔分类器存在且唯一。

➤ 支持向量和间隔


■ **支持向量**：距分离超平面最近的训练样本。

$$y(\mathbf{w}^T \mathbf{x} + b) = 1$$

■ 函数间隔: $\hat{\gamma} = 1$

■ 几何间隔: $\gamma = \frac{1}{\|\mathbf{w}\|_2}$

■ 间隔: $\frac{2}{\|\mathbf{w}\|_2}$



➤ 线性SVM -作业

■ 给定如下训练数据集。

$$\mathbf{x}^1=[3 \ 3]^T, \mathbf{x}^2=[4 \ 3]^T, y^1=1, y^2=1$$

$$\mathbf{x}^3=[1 \ 1], y^3=-1$$

通过求解SVM的原始问题来求解最大间隔的分离超平面。

➤ 拉格朗日对偶：简单情形

■ 等式约束的最优化问题：

$$\min_w f(\mathbf{w})$$

$$s.t. \quad h_i(\mathbf{w}) = 0, \quad i = 1, \dots, l$$

• 拉格朗日函数：

$$L(\mathbf{w}, \boldsymbol{\beta}) = f(\mathbf{w}) + \sum_{i=1}^l \beta_i h_i(\mathbf{w})$$

拉格朗日
乘子

■ 求解：偏导数为0：

$$\frac{\partial L}{\partial w_i} = 0, \quad \frac{\partial L}{\partial \beta_i} = 0$$

➤ 拉格朗日对偶: 一般情形

■ 约束条件中含有等式及不等式约束时:

$$\begin{aligned} \min_{\mathbf{w}} \quad & f(\mathbf{w}) \\ \text{s.t.} \quad & g_i(\mathbf{w}) \leq 0, \quad i = 1, \dots, k \\ & h_i(\mathbf{w}) = 0, \quad i = 1, \dots, l \end{aligned}$$

原问题
Primary Problem

■ 广义拉格朗日函数:

$$L(\mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{w}) + \sum_{i=1}^k \alpha_i g_i(\mathbf{w}) + \sum_{i=1}^l \beta_i h_i(\mathbf{w})$$

非负

拉格朗日乘子

➤ 拉格朗日对偶: 一般情形

■ 定义如下最优化问题:

$$\theta_p(\mathbf{w}) = \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{w}, \alpha, \beta)$$

■ 如 \mathbf{w} 违反了约束条件:

$$\begin{aligned} g_i(\mathbf{w}) &\leq 0, i=1, \dots, k \\ h_i(\mathbf{w}) &= 0, i=1, \dots, l \end{aligned}$$

$$\theta_p(\mathbf{w}) = \max_{\alpha, \beta: \alpha_i \geq 0} f(\mathbf{w}) + \sum_{i=1}^k \alpha_i g_i(\mathbf{w}) + \sum_{i=1}^l \beta_i h_i(\mathbf{w}) =$$



■ 如果满足所有约束条件:

$$\theta_p(\mathbf{w}) = ?$$

➤ 拉格朗日对偶：一般情形

■ 分析下面的最优化问题：

$$\min_{\boldsymbol{w}} \theta_p(\boldsymbol{w}) = \min_{\boldsymbol{w}} \max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0} L(\boldsymbol{w}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

■ 原始问题：

$$\begin{aligned} \min_{\boldsymbol{w}} \quad & f(\boldsymbol{w}) \\ \text{s.t.} \quad & g_i(\boldsymbol{w}) \leq 0, \quad i = 1, \dots, k \\ & h_i(\boldsymbol{w}) = 0, \quad i = 1, \dots, l \end{aligned}$$

■ 定义该问题的最优值：

$$p^* = \min_{\boldsymbol{w}} \theta_p(\boldsymbol{w})$$

原问题的最优值

➤ 拉格朗日对偶：一般情形

■ 对偶问题： $\max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha, \beta: \alpha_i \geq 0} \min_w L(w, \alpha, \beta)$

$$\theta_D(\alpha, \beta) = \min_w L(w, \alpha, \beta)$$

■ 对偶问题的最优值：

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta)$$

■ 原问题与对偶问题：

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_w L(w, \alpha, \beta) \leq \min_w \max_{\alpha, \beta: \alpha_i \geq 0} L(w, \alpha, \beta) = p^*$$

➤ 拉格朗日对偶: 什么时候 $d^*=p^*$?

- 如果原问题是凸优化问题, 且存在严格满足约束条件的 w 。

$$\min_w f(w)$$

$$\text{s.t. } g_i(w) \leq 0, i=1, \dots, k$$

$$h_i(w) = 0, i=1, \dots, l$$

$f(\cdot)$ 、 $g_i(\cdot)$ 是凸函数, $h_i(\cdot)$ 是仿射函数

$$g_i(w) < 0$$

- 则存在 w^*, α^*, β^* , 使得 w^* 是原问题的解, α^*, β^* 是对偶问题的解, 且满足:

$$p^* = d^* = L(w^*, \alpha^*, \beta^*)$$

- w^*, α^*, β^* 满足Karush-Kuhn-Tucker (KKT) 条件:

$$\frac{\partial}{\partial w_i} L(w^*, \alpha^*, \beta^*) = 0, i=1, 2, \dots, M$$

$$g_i(w^*) \leq 0, i=1, \dots, k$$

$$h_i(w^*) = 0, i=1, \dots, l$$

$$\alpha_i^* g_i(w^*) = 0, i=1, \dots, k$$

$$\alpha_i^* \geq 0, i=1, \dots, k$$


KKT 对偶互补性

➤ 最优间隔分类器：对偶解

■ 最优间隔分类器——原问题：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2$$

$$s.t. \ y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq 1, i=1, \dots, N$$



■ 约束条件：

$$g_i(\mathbf{w}) = -y^i (\mathbf{w}^T \mathbf{x}^i + b) + 1 \leq 0, i=1, \dots, N$$

■ KKT对偶互补条件： $\alpha_i^* g_i(\mathbf{w}^*) = 0, i=1, \dots, k$

$$g_i(\mathbf{w}^*) < 0 \Rightarrow \alpha_i^* = 0$$

$$\alpha_i^* \neq 0 \Rightarrow g_i(\mathbf{w}^*) = 0$$

支持向量

■ 支持向量的数量远小于训练样本的数目。

➤ 最优间隔分类器: 对偶解

■ 拉格朗日函数:

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|_2^2 - \sum_{i=1}^N \alpha_i \left[y^i (\mathbf{w}^T \mathbf{x}^i + b) - 1 \right]$$

■ 对偶解:

- 固定 α , 关于参数 \mathbf{w} 和 b 最小化 $L(\mathbf{w}, b, \alpha)$ 得到 $\theta_D(\alpha)$

$$\theta_D(\alpha) = \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$$

- 最大化 $\theta_D(\alpha)$ 得到对偶问题的最优值 d^*


➤ 最优间隔分类器: 对偶解

■ 固定 α , 关于参数 \mathbf{w} 和 b 最小化 $L(\mathbf{w}, b, \alpha)$ 得到 $\theta_D(\alpha)$

• 求解 \mathbf{w} 和 b

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|_2^2 - \sum_{i=1}^N \alpha_i \left[y^i (\mathbf{w}^T \mathbf{x}^i + b) - 1 \right]$$

$$\nabla_{\mathbf{w}} L(\mathbf{w}, b, \alpha) = \mathbf{w} - \sum_{i=1}^N \alpha_i y^i \mathbf{x}^i = 0,$$


$$\mathbf{w} = \sum_{i=1}^N \alpha_i y^i \mathbf{x}^i$$

$$\frac{\partial}{\partial b} L(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i y^i = 0,$$

• 代入拉格朗函数

$$\theta_D(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j.$$

➤ 最优间隔分类器: 对偶解

■ 对偶问题

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j \\ \text{s.t.} \quad & \alpha_i \geq 0, i = 1, \dots, N, \\ & \sum_{i=1}^N \alpha_i y^i = 0. \end{aligned}$$

■ 假设 $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)$ 是对偶问题的最优解, 原问题的解是?

■ 分类超平面是? 判别函数是?

➤ 线性可分SVM (对偶)

■ 输入：线性可分的训练数据集 $S = \{(\mathbf{x}^i, y^i), i=1, \dots, N\}$

■ 输出：分离超平面和判别函数.

• 通过求解对偶问题来得到最优解 $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)$

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j$$

$$s.t. \alpha_i \geq 0, i=1, \dots, N,$$

$$\sum_{i=1}^N \alpha_i y^i = 0.$$

• 得到原问题的最优解 (\mathbf{w}^*, b^*)

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^i \mathbf{x}^i, \quad b^* = y^j - \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x}^j. \quad \alpha_j^* > 0$$

• 分离超平面: $(\mathbf{w}^*)^T \mathbf{x} + b^* = 0$, 判别函数: $f_{\mathbf{w},b}(\mathbf{x}) = (\mathbf{w}^*)^T \mathbf{x} + b^*$.

支持向量

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^i \mathbf{x}^i, \quad b^* = y^j - \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x}^j. \quad \alpha_j > 0$$

- 计算 \mathbf{w}^* 时 b^* ，只需要利用 $\alpha_i > 0$ 的那些样本(支持向量)来计算。

$$f_{\mathbf{w},b}(\mathbf{x}) = (\mathbf{w}^*)^T \mathbf{x} + b^* = \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x} + b^*$$

- 预测时是否需要所有的训练样本来计算？

- 对偶形式：只需计算训练样本与输入特征的内积。

$$(\mathbf{x}^i)^T \mathbf{x} = \langle \mathbf{x}^i, \mathbf{x} \rangle$$

- 核技巧！

➤ 线性可分SVM-作业

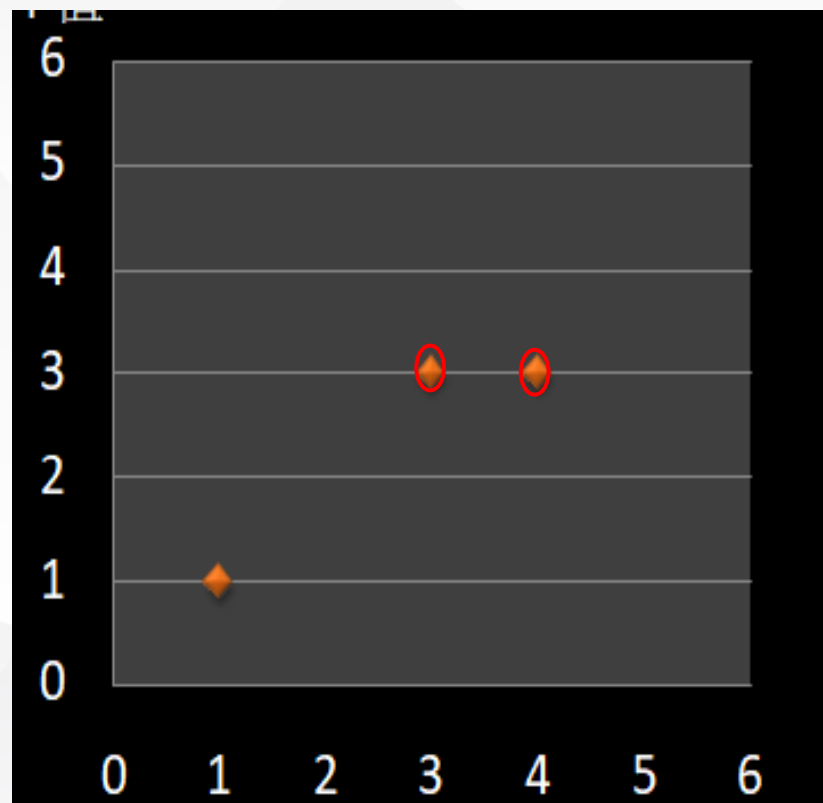
■ • 训练数据

$$\mathbf{x}^1 = [3 \ 3]^T, \mathbf{x}^2 = [4 \ 3]^T,$$

$$y^1 = 1, y^2 = 1$$


$$\mathbf{x}^3 = [1 \ 1]^T, y^3 = -1$$

通过求解对偶问题来得到最大间隔分类器，写出分类超平面及判别函数。



➤ 软间隔 (Soft Margin) 分类器

- 如果训练数据是线性不可分的，怎么办？



➤ 软间隔 (Soft Margin) 分类器

- 允许一些样本 (离群点或噪声样本) 违反原来的不等式约束条件: $y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq 1$, 但是数目要少。

- 目标函数:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N I_{y^i (\mathbf{w}^T \mathbf{x}^i + b) < 1}$$

- 不易求解!

- 替代损失:


0/1损失

hinge损失: $l_{hinge}(z) = \max(0, 1 - z)$

指数损失: $l_{exp}(z) = \exp(-z)$

Huberized损失: $l_{hub}(z) = 0.5 - z, z < 0; 0.5(1 - z)^2, 0 \leq z \leq 1; 0, z > 1$

对率损失(logistic): $l_{log}(z) = \log(1 + \exp(-z))$



➤ 软间隔 (Soft Margin) 分类器

■ Hinge 损失:

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^N \max\{0, 1 - y^i (w^T x^i + b)\}$$

■ 松弛变量 ξ_i :


$$\min_{w,b} \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^N \xi_i$$

$$s.t. \quad y^i (w^T x^i + b) \geq 1 - \xi_i, \quad i = 1, \dots, N,$$

$$\xi_i \geq 0, \quad i = 1, \dots, N.$$

■ 软间隔分类器.

■ 凸二次规划问题。



➤ 软间隔 (Soft Margin) 分类器—对偶问题

■ 拉格朗日函数 $L(\mathbf{w}, b, \xi, \alpha, \eta) = \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i$

$$- \sum_{i=1}^N \alpha_i \left[y^i (\mathbf{w}^T \mathbf{x}^i + b) - 1 + \xi_i \right] - \sum_{i=1}^N \eta_i \xi_i.$$

■ 固定 α, η , 关于参数 \mathbf{w}, b 和 ξ , 最小化 $L(\mathbf{w}, b, \xi, \alpha, \eta)$, 得到 $\theta_D(\alpha, \eta)$

$$\theta_D(\alpha, \eta) = \min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \xi, \alpha, \eta) \quad \left\{ \begin{array}{l} \nabla_{\mathbf{w}} L(\mathbf{w}, b, \xi, \alpha, \eta) = \mathbf{w} - \sum_{i=1}^N \alpha_i y^i \mathbf{x}^i = 0, \Rightarrow \mathbf{w} = \sum_{i=1}^N \alpha_i y^i \mathbf{x}^i \\ \frac{\partial}{\partial b} L(\mathbf{w}, b, \xi, \alpha, \eta) = \sum_{i=1}^N \alpha_i y^i = 0, \\ \frac{\partial}{\partial \xi_i} L(\mathbf{w}, b, \xi, \alpha, \eta) = C - \alpha_i - \eta_i = 0. \end{array} \right.$$

$$\theta_D(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j.$$

■ 最大化 $\theta_D(\alpha, \eta)$, 得到最优值 d^* 。

➤ 软间隔 (Soft Margin) 分类器—对偶问题

■ 对偶问题

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j$$

$$s.t. \ 0 \leq \alpha_i \leq C, i = 1, \dots, N,$$

$$\sum_{i=1}^N \alpha_i y^i = 0.$$

■ 假设 $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)$ 是对偶问题的最优解，
原问题的解是？

■ 分类超平面是？ 分类决策函数是？

➤ 非线性可分 SVM (对偶问题)

■ 输入：训练数据集 $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$

■ 输出：分类超平面与分类决策函数.

• 选择参数 C , 并求解对偶问题, 得最优解 $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)$

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j$$

$$s.t. \ 0 \leq \alpha_i \leq C, i = 1, \dots, N,$$

$$\sum_{i=1}^N \alpha_i y^i = 0.$$

• 求解最优的 (\mathbf{w}^*, b^*) : $\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^i \mathbf{x}^i$, $b^* = y^j - \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x}^j$. $0 < \alpha_j^* < C$

• 分类超平面: $(\mathbf{w}^*)^T \mathbf{x} + b^* = 0$, 判别函数: $f_{\mathbf{w},b}(\mathbf{x}) = (\mathbf{w}^*)^T \mathbf{x} + b^*$.

➤ 非线性SVM: 支持向量

■ 支持向量: $\alpha_i^* > 0$.

■ KKT对偶互补条件: $\alpha_i^* g_i(\mathbf{w}^*) = 0$ $\eta_i^* \xi_i = 0$.

$$\frac{\partial}{\partial \xi_i} L(\mathbf{w}, b, \xi, \alpha, \eta) = C - \alpha_i - \eta_i = 0.$$


$$\alpha_i^* \left[y^i \left((\mathbf{w}^*)^T \mathbf{x}^i + b \right) - 1 + \xi_i \right] = 0, \quad \eta_i^* \xi_i = 0.$$

■ 如果 $\alpha_i^* = 0$, $y^i \left((\mathbf{w}^*)^T \mathbf{x}^i + b_i \right) \geq 1$


■ 如果 $0 < \alpha_i^* < C$, $y^i \left((\mathbf{w}^*)^T \mathbf{x}^i + b_i \right) = 1$

■ 如果 $\alpha_i^* = C$, $y^i \left((\mathbf{w}^*)^T \mathbf{x}^i + b_i \right) \leq 1$


- $0 < \xi_i < 1$
- $\xi_i = 1$
- $\xi_i > 1$



参数 C





Large value for
parameter C



Small value for
parameter C

参数 C



➤ 手写数字识别实验 – KL+linear-SVM

在Minist数据集上进行PCA分析

图像数据维数高，而且特征之间（像素之间）相关性很高，因此我们预计用很少的维数就能保留足够多的信息

```
: #导入必要的工具包
import pandas as pd
import numpy as np
from sklearn import svm
from sklearn.model_selection import train_test_split
from sklearn.decomposition import PCA
import time
from scipy.io import loadmat
```

```
: train = pd.read_csv('./data/MNIST_train.csv').values
test = pd.read_csv('./data/MNIST_test.csv').values
#train
```


```
pca = PCA(n_components=n)
print("PCA begin with n_components: {}".format(n));
pca.fit(X_train)

# 在训练集和测试集降维
X_train_pca = pca.transform(X_train)
X_val_pca = pca.transform(X_val)

# 利用SVC训练
print('SVC begin')
#kernel : 核函数, 默认是rbf, 可以是'linear', 'poly', 'rbf', 'sigmoid', 'precomputed'
clf1 = svm.SVC(kernel='linear')
clf1.fit(X_train_pca, y_train)

# 返回accuracy
accuracy = clf1.score(X_val_pca, y_val)

end = time.time()
print("accuracy: {}, time elaps:{}".format(accuracy, int(end-start)))
return accuracy
```



保留的信息量
降维后，特征维度越高，保留的信息量越多

■ 10类 准确率：
0.98209820

作业

- 推导软间隔SVM的对偶形式。