

● H-K 算法

H-K 算法是求解 $\mathbf{X}\mathbf{w}=\mathbf{b}$ ，式中 $\mathbf{b}=(b_1, b_2, \dots, b_N)^T$ ， \mathbf{b} 的所有分量都是正值。这里要同时计算 \mathbf{w} 和 \mathbf{b} ，我们已知 \mathbf{X} 不是 $N*N$ 的方阵，通常是行多于列的 $N*(n+1)$ 阶的长方形，属于超定方程，因此一般情况下， $\mathbf{X}\mathbf{w}=\mathbf{b}$ 没有唯一确定解，但可求其线性最小二乘解。

设 $\mathbf{X}\mathbf{w}=\mathbf{b}$ 的线性最小二乘解为 \mathbf{w}^* ，即使 $\|\mathbf{X}\mathbf{w}^*-\mathbf{b}\|$ 为极小

采用梯度法，定义准则函数：

$$\begin{aligned} J(\mathbf{w}, \mathbf{x}, \mathbf{b}) &= \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \mathbf{x}^i - b_i)^2 = \frac{1}{2} \sum_{i=1}^N ((\mathbf{x}^i)^T \mathbf{w} - b_i)^2 \\ &= \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{b}\|^2 = \frac{1}{2} (\mathbf{X}\mathbf{w} - \mathbf{b})^T (\mathbf{X}\mathbf{w} - \mathbf{b}) \end{aligned}$$

当 $\mathbf{X}\mathbf{w}=\mathbf{b}$ 的条件满足时， J 达到最小值。由于上式中包括的 $\sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - b_i)^2$ 项为两个数量方差的和，且我们将使其最小化，因此也称之为最小均方误差算法。

使函数 J 同时对变量 \mathbf{w} 和 \mathbf{b} 求最小。对于 \mathbf{w} 的梯度为：

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{b})$$

$$\text{(利用求导公式 } \frac{\partial \mathbf{A}\mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}^T, \quad \frac{\partial \mathbf{x}^T \mathbf{A}\mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{A}^T \mathbf{x} \text{)}$$

使 $\frac{\partial J}{\partial \mathbf{w}} = 0$ ，得 $\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{b}) = 0$ ，从而 $\mathbf{X}^T \mathbf{X}\mathbf{w} = \mathbf{X}^T \mathbf{b}$ 。因为 $\mathbf{X}^T \mathbf{X}$ 为 $(n+1)*(n+1)$ 阶方阵，因此可求得解：

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{b} = \mathbf{X}^\# \mathbf{b}$$

这里 $\mathbf{X}^\# = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ 称为 \mathbf{X} 的伪逆， \mathbf{X} 是 $N*(n+1)$ 阶的长方形。

由上式可知，只要求出 \mathbf{b} 即可求得 \mathbf{w} 。利用梯度法可求得 \mathbf{b} 的迭代公式为：

$$\mathbf{b}(k+1) = \mathbf{b}(k) - C \cdot \left(\frac{\partial J}{\partial \mathbf{b}} \right)_{\mathbf{b}=\mathbf{b}(k)}$$

根据上述约束条件，在每次迭代中， $\mathbf{b}(k)$ 的全部分量只能是正值。由 J 的准则函数式， J 也是正值，因此，当取校正增量 C 为正值时，为保证每次迭代中的 $\mathbf{b}(k)$ 都是正值，应使 $\left(\frac{\partial J}{\partial \mathbf{b}} \right)_{\mathbf{b}=\mathbf{b}(k)}$ 为非正值。在此条件下，准则函数 J 的微分为：

$$-2 \left(\frac{\partial J}{\partial \mathbf{b}} \right)_{\mathbf{b}=\mathbf{b}(k)} = (\mathbf{X}\mathbf{w} - \mathbf{b}) + |\mathbf{X}\mathbf{w} - \mathbf{b}|$$

该式满足以下条件：

$$\text{若 } [\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)] > 0, \text{ 则 } -\left(\frac{\partial J}{\partial \mathbf{b}} \right)_{\mathbf{b}=\mathbf{b}(k)} = \mathbf{X}\mathbf{w}(k) - \mathbf{b}(k).$$

$$\text{若 } [\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)] < 0, \text{ 则 } -\left(\frac{\partial J}{\partial \mathbf{b}} \right)_{\mathbf{b}=\mathbf{b}(k)} = 0$$

由 \mathbf{b} 的迭代式和微分，有：

$$\mathbf{b}(k+1) = \mathbf{b}(k) + \delta \mathbf{b}(k)$$

$$\delta \mathbf{b}(k) = C[\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k) + |\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)|]$$

将此式代入 $\mathbf{w} = \mathbf{X}^\# \mathbf{b}$ ，有：

$$\mathbf{w}(k+1) = \mathbf{X}^\# \mathbf{b}(k+1) = \mathbf{X}^\# [\mathbf{b}(k) + \delta \mathbf{b}(k)] = \mathbf{w}(k) + \mathbf{X}^\# \delta \mathbf{b}(k)$$

为简化起见，令 $\mathbf{e}(k) = \mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)$ ，可得 H-K 算法的迭代式。

设初值为 $\mathbf{b}(1)$ ，其每一分量均为正值，则：

$$\mathbf{w}(1) = \mathbf{X}^\# \mathbf{b}(1)$$

$$\mathbf{e}(k) = \mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)$$

$$\begin{aligned} \mathbf{w}(k+1) &= \mathbf{w}(k) + \mathbf{X}^\# \{C[\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k) + |\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)|]\} \\ &= \mathbf{w}(k) + C\mathbf{X}^\# [\mathbf{e}(k) + |\mathbf{e}(k)|] \end{aligned}$$

由于

$$\begin{aligned} \mathbf{X}^\# \mathbf{e}(k) &= \mathbf{X}^\# [\mathbf{X} \mathbf{w}(k) - \mathbf{b}(k)] = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T [\mathbf{X} \mathbf{w}(k) - \mathbf{b}(k)] \\ &= \mathbf{w}(k) - \mathbf{X}^\# \mathbf{b}(k) = 0 \end{aligned}$$

因此

$$\begin{aligned} \mathbf{w}(k+1) &= \mathbf{w}(k) + C \mathbf{X}^\# |\mathbf{e}(k)| \\ \mathbf{b}(k+1) &= \mathbf{b}(k) + C [\mathbf{X} \mathbf{w}(k) - \mathbf{b}(k) + |\mathbf{X} \mathbf{w}(k) - \mathbf{b}(k)|] \\ &= \mathbf{b}(k) + C [\mathbf{e}(k) + |\mathbf{e}(k)|] \\ &+ \end{aligned}$$

注：常用求导公式：

y 是标量， $\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_d]^T$ 是 d 维列向量，则 $\frac{\partial y}{\partial \mathbf{x}} = \left[\frac{\partial y}{\partial x_1} \ \frac{\partial y}{\partial x_2} \ \cdots \ \frac{\partial y}{\partial x_d} \right]^T$

常用求导公式：

$$\frac{\partial \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}^T$$

$$\frac{\partial \mathbf{x}^T \mathbf{x}}{\partial \mathbf{x}} = 2 \mathbf{x}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}$$