

## ● 单变量正态密度函数的均值学习

设一个模式样本集，其类概率密度函数是单变量正态分布

$N(\theta, \sigma^2)$ ，均值  $\theta$  待求，即

$$p(x|\theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\theta}{\sigma}\right)^2\right]$$

给出  $N$  个训练样本  $\{x^1, x^2, \dots, x^N\}$ ，用贝叶斯学习计算其均值估计量。

设最初的先验概率密度  $p(\theta)$  为  $N(\theta_0, \sigma_0^2)$ ，这里  $\theta_0$  是凭先验知识对未知量  $\theta$  的“最好”推测， $\sigma_0^2$  表示上述推测的不确定性度量。这里可以假定  $p(\theta)$  是正态的，因为均值的估计量是样本的线性函数，因样本  $x$  是正态分布的，因此  $p(\theta)$  取为正态分布是合理的，这样计算起来可比较简单。

初始条件已知，即  $p(\theta)$  为  $N(\theta_0, \sigma_0^2)$ ， $p(x^1|\theta)$  为  $N(\theta, \sigma^2)$ ，由贝叶斯公式  $p(\theta|x^1) = a p(x^1|\theta) p(\theta)$ ，可得：

$$p(\theta|x^1) = a \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x^1-\theta}{\sigma}\right)^2\right] \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\theta-\theta_0}{\sigma_0}\right)^2\right]$$

其中  $a$  是一定值。由贝叶斯法则有：

$$p(\theta|x^1, \dots, x^N) = \frac{p(x^1, \dots, x^N|\theta)p(\theta)}{\int_{\phi} p(x^1, \dots, x^N|\theta)p(\theta)d\theta}$$

这里  $\phi$  表示整个模式空间。由于每一次迭代是从样本子集中逐个抽取一个变量，所以  $N$  次运算是独立地抽取  $N$  个变量，因此上式可写成：

$$p(\theta|x^1, \dots, x^N) = a \left\{ \prod_{k=1}^N p(x^k|\theta) \right\} p(\theta)$$

代入  $p(x^k|\theta)$  和  $p(\theta)$  的值，得：

$$\begin{aligned}
p(\theta | x^1, \dots, x^N) &= a \left\{ \prod_{k=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp \left[ -\frac{1}{2} \left( \frac{x^k - \theta}{\sigma} \right)^2 \right] \right\} \cdot \frac{1}{\sqrt{2\pi}\sigma_0} \exp \left[ -\frac{1}{2} \left( \frac{\theta - \theta_0}{\sigma_0} \right)^2 \right] \\
&= a' \exp \left[ -\frac{1}{2} \left\{ \sum_{k=1}^N \left( \frac{x^k - \theta}{\sigma} \right)^2 \right\} + \left( \frac{\theta - \theta_0}{\sigma_0} \right)^2 \right] \\
&= a'' \exp \left[ -\frac{1}{2} \left\{ \left( \frac{N}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \theta^2 - 2 \left( \frac{1}{\sigma^2} \sum_{k=1}^N x^k + \frac{\theta_0}{\sigma_0^2} \right) \theta \right\} \right]
\end{aligned}$$

上式每一步中与  $\theta$  无关的项都并入常数项  $a'$  和  $a''$ , 这样  $p(\theta | x^1, \dots, x^N)$  是  $\theta$  平方函数的指数集合, 仍是一正态密度函数。将它写成  $N(\theta_N, \sigma_N^2)$  的形式, 即:

$$\begin{aligned}
p(\theta | x_1, \dots, x_N) &= \frac{1}{\sqrt{2\pi}\sigma_N} \exp \left[ -\frac{1}{2} \left( \frac{\theta - \theta_N}{\sigma_N} \right)^2 \right] \\
&= a''' \exp \left[ -\frac{1}{2} \left( \frac{\theta^2}{\sigma_N^2} - 2 \frac{\theta_N \theta}{\sigma_N^2} \right) \right]
\end{aligned}$$

将上述两式相比较, 得:

$$\begin{aligned}
\frac{1}{\sigma_N^2} &= \frac{N}{\sigma^2} + \frac{1}{\sigma_0^2} \\
\frac{\theta_N}{\sigma_N^2} &= \frac{1}{\sigma^2} \sum_{k=1}^N x^k + \frac{\theta_0}{\sigma_0^2} = \frac{N}{\sigma^2} \hat{m}_N + \frac{\theta_0}{\sigma_0^2}
\end{aligned}$$

解出  $\theta_N$  和  $\sigma_N$ , 得:

$$\begin{aligned}
\theta_N &= \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} \hat{m}_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \theta_0 \\
\sigma_N^2 &= \frac{\sigma_0^2 \sigma^2}{N\sigma_0^2 + \sigma^2}
\end{aligned}$$

即根据对训练样本集  $\{x^i\}_{i=1,2,\dots,N}$  的观察, 求得均值  $\theta$  的后验概率密度  $p(\theta | x^i)$  为  $N(\theta_N, \sigma_N^2)$ , 其中  $\theta_N$  是经过  $N$  个样本观察之后对均值的最好估计, 它是先验信息 (即  $\theta_0$ ,  $\sigma_0^2$  和  $\sigma^2$ ) 与训练样本所给信息 (即  $N$  和  $\hat{m}_N$ )

适当结合的结果，是用  $N$  个训练样本对均值的先验估计  $\theta_0$  的补充； $\sigma_N^2$  是对这个估计的不确定性的度量，因  $\sigma_N^2$  随  $N$  的增加而减小，因此当  $N \rightarrow \infty$  时， $\sigma_N^2$  趋于零。由于  $\theta_N$  是  $\hat{m}_N$  和  $\theta_0$  的线性组合，两者的系数都非负且其和为 1，因此只要  $\sigma_0 \neq 0$ ，当  $N \rightarrow \infty$  时， $\theta_N$  趋于样本均值的估计量  $\hat{m}_N$ 。

图中所示为一正态密度的均值学习过程，每增加一次对样本的预测，都可减小对  $\theta$  估计的不确定性，所以  $p(\theta | x^1, \dots, x^N)$  变得越来越峰形突起，且其均值与估计量  $\hat{m}_N$  之间的偏差的绝对值亦越来越小。

