

统计中的因果推断

沈华伟

中国科学院计算技术研究所

» 为什么学习因果推断

■ 克服传统统计方法的不足

- **相关并不意味着因果** (association does not imply causation)
 - 例如：用电量和冰糕销量正相关，但没有因果关系
- **缺少从数据中解读因果关系的有效数学语言或工具**
 - 同样的数据，可以解读出不同的、甚至矛盾的结论
 - 例如：吸烟提高肺癌的患病率吗？
- **统计无法回答反事实问题**
 - 例如：一位硕士生毕业十年后说，如果当年我转博了，现在会怎样？

辛普森悖论 (Simpson's Paradox)

- **总体数据**上得出的统计结论和**分组数据**上的统计结论相反

- **未分组**
 - 吸烟者的成绩比不吸烟者的成绩好
- **按照年龄分组后**
 - 每个分组中，吸烟者的成绩**都**比不吸烟者差
- **继续细分，在年龄的基础上再考虑收入**
 - 结论有可能会进一步反转

辛普森悖论的例子

■ 关于某种药物治疗效果的数据

□ 治疗效果：服药后是否康复

	服药	不服药
男	87人中81人康复 (<u>93%</u>)	270人中234人康复 (<u>87%</u>)
女	263人中192人康复 (<u>73%</u>)	80人中55人康复 (<u>69%</u>)
合计	350人中273人康复 (<u>78%</u>)	350人中289人康复 (<u>83%</u>)

- ✓ 总体数据来看，服药的康复率**低于**不服药的康复率
- ✓ 按照性别分组，每个分组上服药的康复率**均高于**不服药的康复率



» 问题出在了哪里？

- 我们只观测到了数据，对数据背后的产生机制不清楚
- 假如我们了解如下机制
 - 雌性激素对于康复有副作用：女性比男性不易康复
- 解读
 - 总体上，服药的康复率低于不服药的康复率
 - 女性更愿意服药，样本中女性比例更高（相对于随机）
 - 按性别分组后，服药的康复率高于不服药的康复率
 - 排除了雌性激素的影响

问题所在：性别是导致服药和康复的共同原因

» 再看一个类似的例子

■ 锻炼次数和胆固醇指数的关系



年龄高是锻炼次数高和胆固醇指数高的的共同原因

» 再看一个不同的例子

- 和第一个例子中的数据完全相同，只是将分组依据由性别换成了血压。

	不服药	服药
低血压	87人中81人康复 (<u>93%</u>)	270人中234人康复 (<u>87%</u>)
高血压	263人中192人康复 (<u>73%</u>)	80人中55人康复 (<u>69%</u>)
合计	350人中273人康复 (<u>78%</u>)	350人中289人康复 (<u>83%</u>)



- ✓ 总体数据来看，服药的康复率**高于**不服药的康复率
- ✓ 按照血压分组，每个分组上服药的康复率**均低于**不服药的康复率

» 同样的数据为什么结论不同呢？

■ 不同的结论：

- 例子一：应该分组
- 例子二：不应该分组

■ 原因：数据背后的产生机制不同



» 目录

■ 基础知识

- 结构因果模型
- 因果模型图

■ 干预

- 干预与校正公式
- 后门准则
- 前门准则

■ 反事实

- 反事实定义
- 确定性反事实计算
- 非确定性反事实计算

» 结构因果模型 (SCM: Structural Causal Model)

- 结构因果模型用于描述数据的产生机制
- 结构因果模型的构成
 - 外生变量集合： U
 - 外生变量不依赖于其他变量
 - 内生变量集合： V
 - 内生变量至少依赖一个变量
 - 确定内生变量取值的函数集合： F

➤ 例子：教育、工作经验与薪酬水平

■ 结构因果模型

$$U = \{X, Y\}, V = \{Z\}, F = \{f_Z\}$$

$$f_Z: Z = 2X + 3Y$$

X ：受教育年数； Y ：工作年数； Z ：薪酬水平

f_Z 刻画了薪酬水平和受教育年数、工作年数的关系

» 因果模型图

因果模型图以图的方式更直观地表示结构因果模型


结构因果模型

$$U = \{X, Y\}, V = \{Z\}, F = \{f_Z\}$$

$$f_Z: Z = 2X + 3Y$$



因果模型图



- ✓ 因果模型图中，节点表示变量，边表示变量间的依赖关系
- ✓ 因果模型图是一个有向无环图 (DAG: Directed Acyclic Graphs)

» 因果模型图

- 每个结构因果模型对应一个因果模型图
- 因果模型图刻画了变量间的关系，但没有给出依赖关系的具体形式 (f_Z)
- 因果模型图的优点
 - 提供了对因果关系更直观的理解!
 - 能用来非常有效地表示联合分布!


因果模型图

- 通过因果模型图及**乘积分解法则**，可以有效地表示变量联合分布

乘积分解法则: $P(x_1, x_2, \dots, x_n) = \prod_i P(x_i | pa_i)$

- pa_i 表示变量 x_i 的所有父节点

- 例子:




$$P(X = x, Y = y, Z = z) = P(X = x)P(Y = y|X = x)P(Z = z|Y = y)$$

- ✓ 可将“高维”分布估计问题转为一些“低维”分布估计问题，避免“维数灾难”

因果模型图与独立性

■ 链结构



□ 例子： X ——开关， Y ——电路， Z ——灯泡状态


■ 链结构中的条件独立性： $X \perp Z \mid Y$

□ $X = F_X(U_X)$, $Z = F_Z(Y, U_Z)$

□ 给定 Y 时， Z 只受 U_Z 影响， X 只受 U_X 影响，故 X 、 Z 独立（已知外生变量 U_X 和 U_Z 独立）

因果模型图与独立性

■ 分叉结构




- 例子： X ——温度， Y ——冰淇淋销量， Z ——犯罪率

■ 分叉结构中的条件独立性： $Y \perp Z \mid X$

- $Y = F_Y(X, U_Y)$, $Z = F_Z(X, U_Z)$
- 给定 X 时， Y 只受 U_Y 影响， Z 只受 U_Z 影响，故 Y 、 Z 独立（已知外生变量 U_Y 和 U_Z 独立）

因果模型图与独立性

■ 对撞结构



□ 例子：X——音乐天赋， Y——学业成绩， Z——奖学金

■ 对撞结构中的条件独立性： $X \perp Y$

□ 但在给定 Z 或 Z 的子孙时， X 与 Y 不独立（相互依赖）

- 某大学为两类学生提供奖学金（Z）：具有音乐天赋（X）或学业成绩优秀（Y）
- 已知某学生获得了奖学金（ $Z = 1$ ），如果这个人缺乏音乐天赋（ $X = 0$ ）那么必然学业成绩优秀（ $Y = 1$ ）

» 因果模型图与独立性


■ d -分离用于确定因果模型图中任意一对节点是否独立

- 一条路径会被一组节点 Z 阻断，当且仅当：
 - 路径 p 包含链结构 $A \rightarrow B \rightarrow C$ 或分叉结构 $A \leftarrow B \rightarrow C$ ，且中间节点 B 在 Z 中；或
 - 路径 p 包含一个对撞结构 $A \rightarrow B \leftarrow C$ ，且对撞节点 B 及其子孙节点都不在 Z 中。
- 如果一组节点 Z 阻断了 X 和 Y 间的每一条路径，则 X 和 Y 在 Z 的条件下是 d -分离的，即 $X \perp Y \mid Z$

» d - 分离示例

■ 以下一组变量是否能形成变量 x 与 y 的 d - 分离

- $\{T\}$ ✓
- $\{W\}$ ✗
- $\{T, U\}$ ✗
- $\{T, Z\}$ ✓
- $\{W, U, Z\}$ ✗
- $\{U, Z, T\}$ ✓




因果模型图示例

应用例子：基于 d -分离的因果发现

■ 基于 d -分离（独立性）的因果发现

□ 发现与数据对应的因果图模型



产生

X_1	Y_1	Z_1	W_1
X_2	Y_2	Z_2	W_2
.....			
X_n	Y_n	Z_n	W_n



如何从观测数据中发现因果？

真实世界的因果模型（未知）

一堆观测数据（已知）



从数据中可以发现以下变量之间的独立性或条件独立性

$X \perp Y$ 、 $X \not\perp W$ 、 $X \not\perp Z$ 、 $Y \not\perp Z$ 、 $Y \not\perp W$ 、 $Z \not\perp W$
 $Y \not\perp Z|X$ 、 $Y \not\perp W|X$ 、 $Z \not\perp W|X$
 $X \not\perp W|Y$ 、 $X \not\perp Z|Y$ 、 $Z \not\perp W|Y$
 $X \not\perp Y|Z$ 、 $X \perp W|Z$ 、 $Y \perp W|Z$
 $X \perp Y|W$ 、 $X \not\perp Z|W$ 、 $Y \not\perp Z|W$


应用例子：基于 d -分离的因果发现

■ 基于 d -分离（独立性）的因果发现


□ 发现与数据对应的因果图模型

数据中的独立性关系

$X \perp Y、$	$X \not\perp W、$	$X \not\perp Z、$	$Y \not\perp Z、$	$Y \not\perp W、$	$Z \not\perp W$	①
			$Y \not\perp Z X、$	$Y \not\perp W X、$	$Z \not\perp W X$	
$X \not\perp Y Z、$	$X \not\perp W Y、$	$X \not\perp Z Y、$		$Y \perp W Z$	$Z \not\perp W Y$	
$X \perp Y W、$	$X \perp W Z、$	$X \not\perp Z W、$	$Y \not\perp Z W$			
③	②			④		



» 因果之梯



反事实：回答假设性问题

$$P(Y_{X=x} = y | E = e)$$

干预：研究因果效应

$$P(Y = y | do(X = x))$$

联想：数据中寻找相关

$$P(Y = y | X = x)$$

课间休息

» 目录

■ 基础知识

- 结构因果模型
- 因果模型图

■ 干预

- 干预与校正公式
- 后门准则
- 前门准则

■ 反事实

- 反事实定义
- 确定性反事实计算
- 非确定性反事实计算


干预效果预测问题

- **很多统计研究问题本质上是预测某种干预措施的效果**
 - 通过让患者服用某种新癌症药物（实施干预），病人的病情会如何变化？
 - 减少儿童接触暴力电视节目的干预措施，能否降低儿童的攻击性？
 - 通过控制吸烟，是否能有效降低肺癌的患病率？
- **这些干预效果预测问题是否能够通过因果图来表示？**


干预

■ 干预 (Intervention) 的定义

- 将变量固定为某个值，限制了该变量随其他变量而变化的自然趋势
- 记为 $do(X = x)$ ，在因果模型图中即为去掉所有指向 X 的边



因果模型图



干预 X 对应的因果模型图

» 干预 vs. 条件

- 对变量进行干预: $P(Y = y | do(X = x))$
 - 通过干预使 $X = x$ 时 $Y = y$ 的概率
 - 如果群体中的每个个体均将变量 X 的值固定为 x 时, Y 的总体分布
 - 改变了世界 (系统) 本身
- 以变量为条件: $P(Y = y | X = x)$
 - 在 $X = x$ 的条件下 $Y = y$ 的概率
 - 在变量 X 的取值都为 x 的这些个体上, Y 的总体分布
 - 关注问题的子集, 改变的仅是我们对世界的看法

干预效果

■ 平均因果效应 (Average causal effect, ACE)

- 以服药 (X) 是否影响康复 (Y) 为例，服药对康复的因果效应差异为：

- $P(Y = \text{康复} | do(X = \text{服药})) - P(Y = \text{康复} | do(X = \text{不服药}))$



- 传统方法：随机对照试验

- 控制其他变量分布一致，通过改变干预变量，观察其对结果的影响

- 随机对照试验成本高/有时不可行

- 能否从观测数据中直接估计干预效果？

- 校正公式！




校正公式

■ 校正公式

- 在只有观测数据的情况下，计算干预操作的效果

$$\begin{aligned} P(Y = y | do(X = x)) &= P_m(Y = y | X = x) && \text{(由定义)} \\ &= \sum_z P_m(Y = y | X = x, Z = z) P_m(Z = z | X = x) && \text{(全概率公式)} \\ &= \sum_z P_m(Y = y | X = x, Z = z) P_m(Z = z) && \text{(条件独立性)} \\ &= \sum_z P(Y = y | X = x, Z = z) P(Z = z) && \text{(函数不变性)} \end{aligned}$$



校正公式用于解决辛普森悖论

■ 校正公式

$$\square P(Y = y|do(X = x)) = \sum_z P(Y = y|X = x, Z = z)P(Z = z)$$

	服药 (X=1)	不服药 (X=0)
男 (Z=1)	87人中81人康复 (<u>93%</u>)	270人中234人康复 (<u>87%</u>)
女 (Z=0)	263人中192人康复 (<u>73%</u>)	80人中55人康复 (<u>69%</u>)
合计	350人中273人康复 (<u>78%</u>)	350人中289人康复 (<u>83%</u>)

男性比例: 0.51
(87+270)/700

女性比例: 0.49
(263+80)/700

$$\begin{aligned}P(Y = \text{康复}|do(X = 1)) \\&= \sum_z P(Y = \text{康复}|X = 1, Z = z)P(Z = z) \\&= 0.93 \times 0.51 + 0.73 \times 0.49 = 0.832\end{aligned}$$

$$\begin{aligned}P(Y = \text{康复}|do(X = 0)) \\&= \sum_z P(Y = \text{康复}|X = 0, Z = z)P(Z = z) \\&= 0.87 \times 0.51 + 0.69 \times 0.49 = 0.7818\end{aligned}$$

✓ 服药有效: $P(Y = \text{康复}|do(X = 1)) - P(Y = \text{康复}|do(X = 0)) = 0.0502$

➤ 一般化的校正公式

■ 因果效应规则

- 给定一个图 G , 设变量 X 的父节点集合为 PA , 则 X 对 Y 的因果效应为:


$$P(Y = y|do(X = x)) = \sum_z P(Y = y|X = x, PA = z)P(PA = z)$$

Proof (同前面的校正公式类似) :

$$\begin{aligned} P(Y = y|do(X = x)) &= P_m(Y = y|X = x) && \text{(由定义)} \\ &= \sum_z P_m(Y = y|X = x, PA = z)P_m(PA = z|X = x) && \text{(全概率公式)} \\ &= \sum_z P_m(Y = y|X = x, PA = z)P_m(PA = z) && \text{(条件独立性)} \\ &= \sum_z P(Y = y|X = x, PA = z)P(PA = z) && \text{(函数不变性)} \end{aligned}$$

➤ 如果父节点变量不可观测怎么办？

■ 因果模型图示例



■ X 的父节点为 Z ，那么根据一般化校正公式

□ $P(Y = y | do(X = x)) = \sum_z P(Y = y | X = x, Z = z) P(Z = z)$

□ 但由于变量 Z 不可观测，无法从数据中计算上述公式！

➤ 如果父节点变量不可观测怎么办？

■ 后门准则

- 给定因果模型图中一对有序变量 (X, Y) ，若变量集合 Z 满足：
 - Z 阻断了 X 与 Y 之间的每条含有指向 X 的路径（后门路径）
 - Z 中没有 X 的后代节点

则称 Z 满足关于 (X, Y) 的后门准则

■ 后门校正

- 若变量集合 Z 满足 (X, Y) 的后门准则，那么 X 对 Y 的因果效应可由以下公式计算：

$$P(Y = y | do(X = x)) = \sum_z P(Y = y | X = x, Z = z) P(Z = z)$$

直观理解后门准则


■ 后门准则

- 给定因果模型图中一对有序变量 (X, Y) ，若变量集合 Z 满足：
 - Z 阻断了 X 与 Y 之间的每条含有指向 X 的路径
 - Z 中没有 X 的后代节点

1. 阻断 X 和 Y 之间的后门路径
2. 保持从 X 到 Y 的因果路径不变

则称 Z 满足关于 (X, Y) 的后门准则

例子：



$$P(Y = y | do(X = x))$$


1. 变量集合希望阻断可能使 X 和 Y 存在“伪因果”的后门路径，例如 $X \leftarrow Z \rightarrow A \rightarrow Y$
2. 变量 W 不应该被包含在集合 Z 中

- 一条路径会被一组节点 Z 阻断，当且仅当：
 - 路径 p 包含链结构 $A \rightarrow B \rightarrow C$ 或分叉结构 $A \leftarrow B \rightarrow C$ ，且中间节点 B 在 Z 中；
 - 路径 p 包含一个对撞结构 $A \rightarrow B \leftarrow C$ ，且对撞节点 B 及其子孙节点都不在 Z 中。


该因果模型图中变量 A 满足关于 (X, Y) 的后门准则

➤ 例子：满足后门准则的变量集

■ 找出满足变量对 (X, Y) 的后门准则的变量集




- $\{Z\}$ ✗
- $\{E, Z\}$ ✓
- $\{F, Z\}$ ✓
- $\{E, F\}$ ✗
- $\{E, F, Z\}$ ✓



- $\{Z\}$ ✗
- $\{F, Z\}$ ✓
- $\{A, Z\}$ ✓
- $\{W, A, Z\}$ ✗
- $\{A, F, Z\}$ ✓

➤ 例子：应用后门校正估计因果效应

■ 因果模型图示例



- 变量集合 W 满足变量对 (X, Y) 的后门准则，那么根据后门校正公式：


$$\square P(Y = y | do(X = x)) = \sum_w P(Y = y | X = x, W = w) P(W = w)$$

如果后门准则也不满足怎么办？

■ 因果模型图示例

- 需要估计因果效应

$$P(Y = y | do(X = x))$$



■ 变量 X 的父节点为 U (不可观测)

- 无法应用一般化校正公式！

■ 满足变量对 (X, Y) 后门准则的变量为 U (不可观测)

- 无法应用后门校正公式！

如果后门准则也不满足怎么办？

■ 通过中介变量估计因果效应 $P(Y = y | do(X = x))$

□ Z 是 X 到 Y 的中介变量

□ X 到 Z 的因果效应


$$\begin{aligned} P(Z = z | do(X = x)) \\ = P(Z = z | X = x) \quad \text{(无后门路径)} \end{aligned}$$

□ Z 到 Y 的因果效应

$$\begin{aligned} P(Y = y | do(Z = z)) \\ = \sum_x P(Y = y | Z = z, X = x) P(X = x) \quad \text{(后门校正)} \end{aligned}$$

■ 结合 X 到 Z 的因果效应以及 Z 到 Y 的因果效应，得到 X 到 Y 的整体因果效应

$$\begin{aligned} P(Y = y | do(X = x)) &= \sum_z P(Z = z | do(X = x)) P(Y = y | do(Z = z)) \\ &= \sum_z P(Z = z | X = x) \sum_{x'} P(Y = y | Z = z, X = x') P(X = x') \end{aligned}$$



» 如果后门准则也不满足怎么办？

■ 前门准则

- 给定因果模型图中一对有序变量 (X, Y) ，若变量集合 Z 满足：
 - Z 切断了所有 X 到 Y 的有向路径；
 - X 到 Z 没有后门路径；
 - 所有 Z 到 Y 的后门路径都被 X 阻断

则称 Z 满足关于 (X, Y) 的前门准则

■ 前门校正

- 若变量集合 Z 满足 (X, Y) 的前门准则，那么 X 对 Y 的因果效应可由以下公式计算：

$$P(Y = y | do(X = x)) = \sum_z P(Z = z | X = x) \sum_{x'} P(Y = y | Z = z, X = x') P(X = x')$$

» 目录

■ 基础知识

- 结构因果模型
- 因果模型图

■ 干预

- 干预与校正公式
- 后门准则
- 前门准则

■ 反事实

- 反事实定义
- 确定性反事实计算
- 非确定性反事实计算

» 反事实例子

- 当昨天晚上驾车回家的时候，我在一个路口需要作出选择：走高速公路（ $X = 1$ ）还是走国道（ $X = 0$ ）
- 我选择了走国道（ $X = 0$ ），结果发现交通非常拥堵——用了一个小时（ $Y = 1$ 小时）才到家。
- 此时我后悔地想：“如果当初我走高速公路，应该会更快到家吧！”

这种“如果”的陈述形式被称作反事实

» 反事实内涵与符号表示

■ 反事实内涵

- 反事实陈述句：如果……，那么……
 - “如果”部分称为假设条件
- 反事实强调在完全一致的现实条件下，比较不同假设条件的结果
 - 创造了与真实世界不同的平行世界

■ 反事实符号表示

- 由于假设条件 (X) 的取值不同而创造出了不同的世界，用下标表示。
- 不同世界下 Y 的取值记为 $Y_{X=x}$ (或 Y_x)

» 再来看刚才的例子

- 已知现实世界

- $X = 0$ (走国道) , $Y = 1$ (驾驶时间1小时)

- 那么反事实想回答的问题是

- 如果当初 $X = 1$ (走高速) , 那么驾驶时间 $Y_{X=1}$ 的期望是多少?

$$E(Y_{X=1} | X = 0, Y = Y_0 = 1)$$

反事实世界 (假设当初走高速)

现实世界 (观测变量)

» 反事实 vs. 干预

■ 干预

- 讨论的是某个操作所带来的因果效应。没办法区分现实世界和反事实世界。

- 例如 $P(\text{驾驶时间} | do(X = \text{国道}))$, $P(\text{驾驶时间} | do(X = \text{高速}))$

- 在总体上进行

■ 反事实

- 讨论的是在两个平行世界中发生的不同事件（现实世界与反事实世界），**需要保持世界中其他环境/个体条件完全一致**

- 在个体或群体上进行

» 反事实怎么计算？

■ 回顾结构因果模型 M

- 外生变量集合 U , 内生变量集合 V , 确定内生变量集合的函数/方程集合 $\{F\}$
- 外生变量取值 $U = u$ 确定了当前个体或环境或情形


■ 给定观测 $E = e$, 反事实 $Y_{X=x}$ 的三步法计算:

- **溯因**: 用观测/证据 $E = e$ 确定当前个体/环境, 即 U 的值
- **作用**: 修改结构因果模型 M , 移除变量 X 出现在左边的方程并用 $X = x$ 来替换它们, 从而获得修正的模型 M_x
- **预测**: 使用修正后的模型 M_x 和 U 的值来计算 Y 的值, 即反事实结果

➤ 例子：课后补习、家庭作业与成绩

■ 课后补习、家庭作业量与考试成绩的结构因果模型

- X ：学生在课后补习上花费的时间
- H ：家庭作业量
- Y ：考生考试成绩



因果模型图

■ 考虑一个名为乔的学生

- 观测 $X = 0.5$, $H = 1$, $Y = 1.5$
- 反事实问题：如果家庭作业量 H 加倍，他的考试成绩会更高吗？

$$\begin{aligned} X &= U_X \\ H &= 0.5X + U_H \\ Y &= 0.7X + 0.4H + U_Y \end{aligned}$$


结构因果模型

➤ 例子：课后补习、家庭作业与成绩

■ 反事实计算过程

- 溯因：根据 $e = \{X = 0.5, H = 1, Y = 1.5\}$ 推断个体的 U
 - $U_X = 0.5, U_H = 1 - 0.5 \times 0.5 = 0.75, U_Y = 1.5 - 0.7 \times 0.5 - 0.4 \times 1 = 0.75$
- 作用：移除变量 H 出现在左边的方程并用 $H = 2$ 来替换
- 预测： $Y_{H=2}(U_X = 0.5, U_H = 0.75, U_Y = 0.75) = 1.9 > 1.5$

反事实答案：如果家庭作业量 H 加倍，乔的考试成绩会更高！



因果模型图

$$\begin{aligned} X &= U_X \\ H &= 0.5X + U_H \\ Y &= 0.7X + 0.4H + U_Y \end{aligned}$$

结构因果模型


➤ 如果根据观测无法唯一确定个体/环境呢？

- 对于 $E(Y_{X=x}|E=e)$ 的非确定性反事实，三步法为：
 - **溯因**：用观测/证据 $E=e$ 更新 $P(U)$ ，获得 $P(U|E=e)$
 - **作用**：修改结构因果模型 M ，移除变量 X 出现在左边的方程并用 $X=x$ 来替换它们，从而获得修正的模型 M_x
 - **预测**：使用修正后的模型 M_x 和 $P(U|E=e)$ 的值来计算 Y 的期望，即反事实结果

» 例子：教育、技能与薪资

■ 教育水平、技能水平与薪资的因果结构模型

- X : 教育水平
- Z : 工作所需的技能水平
- Y : 薪资



因果模型图

- 对于那些观测到技能水平 $Z = 1$ 的个体
 - 反事实问题：如果这些个体当初接受了高等教育 ($X = 1$)，他们的期望薪资会是多少？

$$\begin{aligned} X &= U_X \\ Z &= X + U_Z \\ Y &= Z \\ U_X, U_Z &\in \{0, 1\} \end{aligned}$$

结构因果模型

» 例子：教育、技能与薪资

■ 非确定性反事实计算过程

□ 溯因：用观测 $e = \{Z = 1\}$ 更新 $P(U)$ ，获得 $P(U|E = e)$


$$\blacksquare P(U_X = 0, U_Z = 1|Z = 1) = \frac{P(U_X=0, U_Z=1)}{P(U_X=0, U_Z=1) + P(U_X=1, U_Z=0)} = p_1$$

$$\blacksquare P(U_X = 1, U_Z = 0|Z = 1) = \frac{P(U_X=1, U_Z=0)}{P(U_X=0, U_Z=1) + P(U_X=1, U_Z=0)} = p_2$$

□ 作用：移除变量 X 出现在左边的方程并用 $X = 1$ 来替换

□ 预测： $E(Y_{X=1}|Z = 1) = p_1 Y_{X=1}(U_X = 0, U_Z = 1) + p_2 Y_{X=1}(U_X = 1, U_Z = 0) = 2p_1 + p_2$

因果模型图



$$\begin{aligned} X &= U_X \\ Z &= X + U_Z \\ Y &= Z \\ U_X, U_Z &\in \{0, 1\} \end{aligned}$$

结构因果模型

➤ 如果未知因果结构模型怎么办？

■ 后门的反事实定理

- 如果一个变量集合 Z 满足 (X, Y) 的后门条件，那么对于所有的 x ，在给定 Z 条件下，反事实条件 $Y_{X=x}$ 独立于 X ，记为：

$$P(Y_x|X, Z) = P(Y_x|Z)$$

■ 反事实结果可以通过观测数据进行估计：

$$P(Y_x = y) = \sum_z P(Y_x = y|Z = z)P(z) \quad (\text{全概率公式})$$

$$= \sum_z P(Y_x = y|Z = z, X = x)P(z) \quad (\text{后门的反事实定理})$$

$$= \sum_z P(Y = y|Z = z, X = x)P(z) \quad (\text{反事实一致性原则})$$

» 小结

- **统计中的因果推断具有重要意义**
 - **克服基于统计相关的机器学习面临的一些问题**
 - 模型鲁棒性问题：OOD (out of distribution)
 - 反事实问题：模型去偏等
- **因果模型图给因果推断提供了简洁的数学工具**
 - 独立性判定
 - 干预效应
 - 反事实推理
- **因果推断是近年来的学术前沿，其应用方兴未艾**

下课